Hecho por Tomás Jarufe · tjarufe@usm.cl · https://tomasjarufe.site/

MAT 70725 – PROBABILIDAD Y ESTADÍSTICA

Control #4 (simulado) – Estadística Descriptiva

Nota: no creo que el control real sea tan largo. Son solo 2 ejercicios que reúnen preguntas y trampas que podrían aparecer.

Ejercicio 1

ver pauta →

Una central de mantenimiento registró, para 25 llamados de emergencia escogidos al azar, el tipo de equipo con falla, codificado como E (Eléctrico), M (Mecánico), H (Hidráulico) y N (Neumático), el tiempo de respuesta (en minutos) y el número de técnicos enviados:

Equipo	E	E	M	M	M	M	M	H	M	H	E	E	E
Tiempo	14,2	17,6	11,0	20,8	22,4	15,7	11,8	34,6	12,6	11,3	15,3	8,4	17,0
Técnicos	3	4	3	2	2	4	1	3	3	4	1	1	2
Equipo	M	E	N	N	M	H	N	E	H	N	H	E	
Tiempo	12,4	14,8	19,2	13,5	10,2	16,4	9,7	9,1	18,5	13,9	10,5	13,1	
Técnicos	2	2	2	2	3	2	1	3	1	3	1	2	

Para el tiempo de respuesta se sabe además que

$$\sum_{j=1}^{25} x_j = 374{,}0 \qquad s = 5{,}4987 \qquad m_3 = 293{,}1292 \qquad m_4 = 6355{,}5225$$

a. Para cada variable, determine si es cualitativa o cuantitativa, discreta o continua, e indique su escala de medición. Organice las variables "equipo" y "número de técnicos" en tablas de frecuencias, incorporando todas las frecuencias admisibles.

b. Determine e interprete una medida de tendencia central adecuada para el tiempo de respuesta. Justifique su elección.

c. ¿Qué porcentaje de los llamados tuvo un tiempo de respuesta superior al valor obtenido en **b.**?

d. ¿Existen tiempos de respuesta atípicos? Justifique numéricamente.

e. Calcule e interprete el sesgo y la curtosis de Fisher del tiempo de respuesta. ¿Es razonable resumir este tiempo mediante la media?

f. Determine el tipo de equipo más frecuente y evalúe su representatividad. ¿Qué porcentaje de los llamados requirió al menos 3 técnicos?

g. La central incorporará un registro fijo de 1,5 minutos a cada llamado. Sin recalcular a partir de los datos, determine la media, la desviación estándar, el coeficiente de variación y el sesgo de Fisher del nuevo tiempo de respuesta.

h. Un supervisor afirma: "el coeficiente de variación del tiempo de respuesta es alto, así que la central es poco regular". Calcule el coeficiente de variación y comente si, con la información disponible, es posible respaldar esta afirmación.

Ejercicio 2

ver pauta →

Con el propósito de planificar el abastecimiento, una empresa sanitaria registró el consumo mensual de agua (en m³) de 200 viviendas de un sector A, obteniéndose:

Consumo (m³)	Nr. de viviendas
0 – 10	20
10 – 15	45
15 – 20	35
20 – 30	50
30 – 50	40
50 – 80	10

a. Identifique y clasifique la variable bajo estudio. Determine una medida de tendencia central para el consumo e interprétela.

b. ¿Cuál es el consumo más frecuente?

c. ¿Qué porcentaje de las viviendas consume más que la mediana? ¿Qué consumo es superado por el 25 % de las viviendas?

d. Calcule el consumo promedio y la desviación estándar. ¿Qué porcentaje de las viviendas tiene un consumo dentro del intervalo $\bar{x} \mp 2\,s$?

e. La empresa aplica un recargo a las viviendas que consumen más de 30 m³. De las viviendas con recargo, ¿qué porcentaje consume más de 50 m³?

f. En un sector B se registró un consumo promedio de 12,5 m³ con una desviación estándar de 9,1 m³. ¿Qué sector presenta consumos más homogéneos? Justifique.

g. Se sabe que $m_3 = 3267{,}62$ y $m_4 = 173\,289{,}49$. Comente la simetría. ¿Es correcto afirmar que la distribución del consumo presenta “mayor dispersión” respecto a una distribución normal?

Pauta

Los números entre corchetes, como [11], son las fórmulas del Formulario 5.

Solución 1

↑ ver enunciado

a. **Equipo:** cualitativa, escala nominal. **Tiempo de respuesta:** cuantitativa continua, escala de razón. **Número de técnicos:** cuantitativa discreta, escala de razón.

Equipo	n_i	f_i
E	8	0,32
M	8	0,32
H	5	0,20
N	4	0,16
Total	25	1

Técnicos	n_i	f_i	N_i	F_i
1	6	0,24	6	0,24
2	9	0,36	15	0,60
3	7	0,28	22	0,88
4	3	0,12	25	1
Total	25	1		

El equipo no admite frecuencias acumuladas (no hay orden); los técnicos sí.

b. Ordenando: 8,4 9,1 9,7 10,2 10,5 11,0 **11,3** 11,8 12,4 12,6 13,1 13,5 **13,9** 14,2 14,8 15,3 15,7 16,4 **17,0** 17,6 18,5 19,2 20,8 22,4 34,6.

$$Me = X_{(\frac{25+1}{2})} = X_{(13)} = 13{,}9 \text{ min} \quad [2]$$

El 50 % de los llamados tuvo un tiempo de respuesta de a lo más 13,9 minutos. Es la medida adecuada porque el tiempo de 34,6 min se aleja mucho del resto (ver **d.**) y arrastra a la media, $\bar{x} = 374/25 = 14{,}96$ [1].

Ojo: con n impar la mediana es un dato de la muestra y sale con solo ordenar. Además es la medida *adecuada*; la media, aunque sea fácil con $\sum x_j$, no lo es.

c. Por definición, aproximadamente el 50 %. Contando exactamente, sobre 13,9 hay 12 de los 25 datos:

$$\tfrac{12}{25} = 48\,\%$$

Ojo: no hay que calcular nada: superar la mediana es superar "la mitad". No da exactamente 50 % porque con n impar la propia mediana es uno de los datos.

d. Con [3]–[4] y $n = 25$: Q_1: $h = 1 + \frac{25\cdot 24}{100} = 7 \Rightarrow Q_1 = X_{(7)} = 11{,}3$. $\quad Q_3$: $h = 19 \Rightarrow Q_3 = X_{(19)} = 17{,}0$.

$$RIQ = 5{,}7 \ [18] \qquad Q_1 - 1{,}5\,RIQ = 2{,}75 \qquad Q_3 + 1{,}5\,RIQ = 25{,}55$$

Sí: el tiempo de 34,6 min supera 25,55, así que es atípico. Ningún dato queda bajo 2,75.

Ojo: las fronteras $Q_1 - 1{,}5RIQ$ y $Q_3 + 1{,}5RIQ$ **no están en el formulario**: hay que sabérselas.

e.

$$\gamma_1 = \frac{m_3}{s^3} = \frac{293{,}1292}{5{,}4987^3} = 1{,}763 \ [21] \qquad \gamma_2 = \frac{m_4}{s^4} - 3 = \frac{6355{,}5225}{5{,}4987^4} - 3 = 3{,}952 \ [22]$$

Asimetría positiva marcada (cola hacia los tiempos largos) y distribución leptocúrtica (apuntada, con colas pesadas): ambas cosas las produce principalmente el dato atípico. No es razonable resumir el tiempo con la media; la mediana es más representativa.

f. $Mo = \{\text{Eléctrico, Mecánico}\}$: distribución **bimodal**. Para cada moda, $V_{Mo} = 1 - \frac{8}{25} = 0{,}68$ [17]: poco representativa, porque el 68 % de los llamados corresponde a otro tipo de equipo.
Al menos 3 técnicos: $1 - F_2 = 1 - 0{,}60 = 40\,\%$.

Ojo: hay que reportar *las dos* modas. Y "al menos 3" es $1 - F_2$, no $1 - F_3$.

g. Con $Y = X + 1{,}5$: la media se traslada y la dispersión y la forma no cambian.

$$\bar{y} = 14{,}96 + 1{,}5 = 16{,}46 \qquad s_Y = 5{,}4987 \qquad CV_Y = \tfrac{5{,}4987}{16{,}46} = 0{,}334 \ [19] \qquad \gamma_{1,Y} = 1{,}763$$

Ojo: el CV *sí* cambia (antes era 0,368): sube la media y s queda igual.

h.

$$CV = \frac{s}{\bar{x}} = \frac{5{,}4987}{14{,}96} = 0{,}368 \quad [19]$$

La desviación estándar equivale a cerca de un 37 % del tiempo medio. Pero con la información disponible **no se puede afirmar** que el CV sea "alto": no hay otra central, otro periodo ni un estándar contra el cual compararlo, y el CV no tiene un valor de corte oficial. Lo que sí se puede decir es su magnitud relativa. Además, este CV está inflado por el dato atípico (34,6 min), que aumenta s y $\bar{x}$ de forma desigual, así que tampoco describe bien la regularidad del grueso de los llamados.

Ojo: el CV sirve sobre todo para *comparar* grupos. Por sí solo, "alto" o "bajo" no se puede afirmar con rigor; lo correcto es interpretarlo ("la desviación es un 37 % de la media") y decir que falta una referencia.

Solución 2

↑ ver enunciado

Amplitudes: 10, 5, 5, 10, 20, 30 (distintas). N_j: 20, 65, 100, 150, 190, 200. Marcas: 5; 12,5; 17,5; 25; 40; 65.

a. Consumo mensual de agua de una vivienda: cuantitativa continua, escala de razón.
$\frac{n}{2} = 100 = N_3$ *exactamente*, así que la mediana es el límite superior de la 3.ª clase:

$$Me = 15 + \big(100 - 65\big)\tfrac{5}{35} = 20 \text{ m}^3 \quad [11]$$

El 50 % de las viviendas consume a lo más 20 m³ al mes.

Ojo: piden "una" medida: la mediana sale sin interpolar. La media exige todas las marcas, y la moda tiene una trampa (ver **b.**).

b. Con amplitudes distintas se comparan **densidades** n_j/a_j:

Clase	0–10	10–15	15–20	20–30	30–50	50–80
n_j/a_j	2	**9**	7	5	2	0,33

La clase modal es 10–15. Con densidades en [13]: $d_1 = 9 - 2 = 7$ y $d_2 = 9 - 7 = 2$:

$$Mo = 10 + \tfrac{7}{7+2} \cdot 5 = 13{,}89 \text{ m}^3 \quad [12]$$

Ojo: la clase con más viviendas (20–30, con 50) **no** es la modal: es el doble de ancha. Usando n_j se obtiene $Mo = 26$, que es incorrecto.

c. Más que la mediana: **50 %**, sin calcular.
Consumo superado por el 25 %: es P_{75}. Como $200 \cdot 0{,}75 = 150 = N_4$ exactamente:

$$P_{75} = 20 + (150 - 100)\tfrac{10}{50} = 30 \text{ m}^3$$

Ojo: "superado por el 25 %" es P_{75}, no P_{25}; y de nuevo cae justo en un límite de clase.

d.

$$\bar{x} = \sum f_j m_j = \tfrac{20(5)+45(12{,}5)+35(17{,}5)+50(25)+40(40)+10(65)}{200} = 23{,}875 \text{ m}^3 \quad [10]$$

$$s^2 = \sum f_j m_j^2 - \bar{x}^2 = 778{,}75 - 23{,}875^2 = 208{,}73 \;\Rightarrow\; s = 14{,}45 \text{ m}^3 \quad [14],[20]$$

$\bar{x} \mp 2s = [-5{,}02;\ 52{,}77]$. El extremo inferior está bajo 0 (el primer límite), así que $k_1 = 0$. Para el superior, en la clase 50–80:

$$52{,}77 = 50 + \left(200\tfrac{k_2}{100} - 190\right)\tfrac{30}{10} \;\Rightarrow\; k_2 = 95{,}46 \qquad \Rightarrow \qquad k_2 - k_1 = 95{,}46\,\%$$

Ojo: un extremo fuera de la tabla no se interpola: ese lado vale 0 %.

e. Más de 30 m³: $200 - N_4 = 50$ viviendas. Más de 50 m³: $200 - N_5 = 10$ viviendas. Ambos valores son límites de clase, así que no hay que interpolar:

$$\tfrac{10}{50} = 20\,\% \text{ de las viviendas con recargo}$$

Ojo: la base son las 50 viviendas con recargo, no las 200 (sobre el total serían 5 %).

f.

$$CV_A = \tfrac{14{,}45}{23{,}875} = 0{,}605 \qquad CV_B = \tfrac{9{,}1}{12{,}5} = 0{,}728 \quad [19]$$

El sector A es más homogéneo, porque tiene menor CV.

Ojo: B tiene menor desviación estándar (9,1 contra 14,45), pero su media es mucho menor: en términos relativos varía más.

g.

$$\gamma_1 = \frac{3267{,}62}{14{,}448^3} = 1{,}084 \;[21] \qquad \gamma_2 = \frac{173\,289{,}49}{208{,}73^2} - 3 = 0{,}977 \;[22]$$

Asimetría positiva: cola hacia los consumos altos (coherente con $Mo < Me < \bar{x}$). Como $\gamma_2 > 0$, la distribución es leptocúrtica, así que **no** es correcto: "mayor dispersión" respecto a la normal corresponde a una distribución platicúrtica ($\gamma_2 < 0$). Aquí hay mayor concentración que en la normal.