Hecho por Tomás Jarufe · tjarufe@usm.cl · https://tomasjarufe.site/

Estadística Descriptiva I

Datos, escalas, tablas de frecuencia y gráficos

MAT 70725 · Probabilidad y Estadística · UTFSM · 1 de noviembre de 2026

> *Hasta ahora partía del modelo ($X \sim$ algo) y calculaba probabilidades. Ahora es al revés: tengo **datos** y quiero resumirlos (descriptiva) para después inferir el modelo que los generó (inferencial).*

1 Conceptos base

1.1 Medición y tipos de variables

Medir = asignar símbolos o códigos (números, letras, categorías) a objetos o sucesos reales. Si esa asignación está mal hecha, hay **error de medición**.

Tipo	Qué es	Ejemplo
Cualitativa (categórica)	Etiqueta o categoría	Empresa de telefonía, forma de pago
Cuantitativa discreta	Número que se *cuenta*	N.º de mantenciones de un equipo
Cuantitativa continua	Número que se *mide*	Tiempo de espera en segundos

1.2 Escalas de medición

Cada escala *agrega* una propiedad a la anterior: lo que puedo hacer con los datos depende de la escala.

Escala	Agrega	Qué permite	Ejemplo
Nominal	Clasificar	Contar por categoría ($=$, $\neq$)	Forma de pago, color
Ordinal	+ Orden	Decir cuál es mayor ($<$, $>$)	Nivel educacional, nota A/B/C
Intervalar	+ Distancia	Restar: las diferencias significan algo	Temperatura en °C, año
Razón	+ Cero real	Dividir: "el doble de" tiene sentido	Peso, tiempo, ingresos

¿Por qué los °C no son de razón?

El 0 °C no significa "ausencia de temperatura", es un cero arbitrario. Por eso 20 °C no es "el doble de calor" que 10 °C, aunque la diferencia de 10 °C sí tiene sentido. En cambio 0 s sí es "nada de tiempo": 20 s es el doble de 10 s.

1.3 Población, muestra y muestreo

- **Población**: todos los elementos sobre los que quiero información. **Censo** = estudiarla entera.
- **Muestra**: subconjunto seleccionado. Debe ser **representativa** (reflejar los atributos de la población).
- La información de una muestra depende de su **tamaño** y de la **variabilidad** de los datos (que un buen diseño puede reducir).
- **Diseño de muestreo** = el procedimiento para elegir la muestra. Un buen diseño logra la misma precisión con menos datos (más barato).
- Muestreo **probabilístico** (aleatorio): cada elemento tiene probabilidad *conocida* (no necesariamente igual) de salir. Principio clave: **aleatorizar**. El otro tipo es el no probabilístico.

Muestreo probabilístico	Idea
Aleatorio simple	Todos tienen la misma chance; se sortea directo.
Estratificado	Divido en grupos homogéneos (estratos) y sorteo dentro de cada uno.
Conglomerados	Divido en grupos "mini-población" y sorteo grupos completos.
Sistemático	Elijo uno al azar y después cada k-ésimo de la lista.

2 Tablas de frecuencias

Agrupo las n observaciones en k clases $C_1, \ldots, C_k$ (categorías o intervalos).

Frecuencias

Absoluta	$n_i = \#\{\text{obs.} \in C_i\}$	cuántos datos caen en la clase
Relativa	$f_i = \dfrac{n_i}{n}$	qué proporción son; $\sum f_i = 1$
Absoluta acumulada	$N_p = \sum_{j=1}^{p} n_j, \;\; N_k = n$	cuántos datos hay hasta la clase p
Relativa acumulada	$F_p = \sum_{j=1}^{p} f_j, \;\; F_k = 1$	proporción hasta la clase p

Ojo

n_i y f_i sirven para **cualquier escala**. Las **acumuladas** exigen escala **al menos ordinal**: "acumular hasta la clase p" supone que las clases tienen orden. En los ejemplos de clase, R imprime columnas "% Cum." para la forma de pago (nominal): **esas columnas no tienen sentido** y hay que borrarlas. Es la pregunta trampa "¿son todas las columnas correctas?".

F_p es la versión con datos de F_X

F_p = proporción de datos $\leq$ clase p. Es lo mismo que $F_X(x) = \mathbb{P}[X \leq x]$, pero calculado con la muestra en vez de con el modelo. Por eso termina en 1 y nunca baja.

Ejemplo mini (discreta)

N.º de mantenciones en 36 equipos. Se tabula valor a valor:

x	0	1	2	3	4	5	6	7	Total
n_i	6	5	4	7	4	6	1	3	36
f_i	0,1667	0,1389	0,1111	0,1944	0,1111	0,1667	0,0278	0,0833	1
N_i	6	11	15	22	26	32	33	36	
F_i	0,1667	0,3056	0,4167	0,6111	0,7222	0,8889	0,9167	1	

Lectura: $F_3 = 0{,}6111 \Rightarrow$ el 61 % de los equipos tuvo 3 mantenciones o menos.

2.1 Datos continuos: tabla por intervalos

Con una variable continua casi todos los valores son distintos: una tabla valor a valor queda enorme y el gráfico tiene demasiadas barras. Hay que **agrupar en intervalos**.

Algoritmo para construir los intervalos

1. **N.º de clases (Sturges):** $k = 1 + 3{,}3 \log_{10} n$, aproximado idealmente al **impar** más cercano.
2. **Rango de los datos:** $R_D = \max\{x_i\} - \min\{x_i\}$.
3. **Unidad mínima de medida** u (ej. datos enteros $\Rightarrow u = 1$; con un decimal $\Rightarrow u = 0{,}1$).
4. **Amplitud:** $a = \dfrac{R_D + u}{k}$.
5. **Rango de la tabla:** $R_T = k \cdot a$, y sobrante $D = R_T - R_D$.
6. **Primer límite inferior:** $LI_1 = \min\{x_i\} - \dfrac{D}{2}$. Luego $LI_2 = LI_1 + a$, y así hasta la clase k.

¿Por qué el $+u$ y el $D/2$?

Si uso $a = R_D/k$ justo, el máximo queda pegado al borde y con intervalos $[\,\cdot\,,\cdot\,)$ se quedaría fuera. Sumar u agranda un poco la tabla para que *todos* los datos entren. El sobrante D se reparte mitad abajo y mitad arriba para que la tabla quede centrada en los datos.

Ejemplo mini (tiempos de espera)

$n = 117$ tiempos (en s, enteros), min $= 11$, max $= 70$. $k = 1 + 3{,}3 \log_{10} 117 \approx 7{,}82 \Rightarrow k = 7$ (impar más cercano). $R_D = 59$, $u = 1$, $a = 60/7 \approx 8{,}57$, $R_T = 60$, $D = 1$, $LI_1 = 11 - 0{,}5 = 10{,}5$.

Ojo

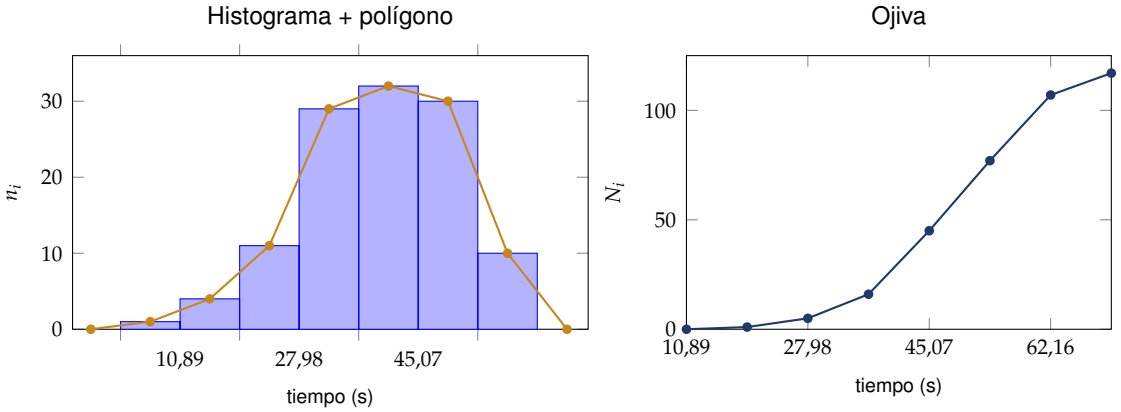
La tabla de las diapositivas, $[10{,}89;\ 19{,}43), \ldots$, la hizo el paquete `fdt` de R, que usa *su propia* regla para los bordes (min -1% y max $+1\%$). Por eso no coincide con el algoritmo manual. **El profe dijo que el algoritmo era solo para verlo: en la prueba no se usa.** Allí me darán la tabla hecha y trabajo con esa.

La tabla de clase (la usaré también en la parte 2), con la **marca de clase** m_i = punto medio del intervalo:

Clase	m_i	n_i	f_i	N_i	F_i
$[10{,}89;\ 19{,}43)$	15,16	1	0,0085	1	0,0085
$[19{,}43;\ 27{,}98)$	23,71	4	0,0342	5	0,0427
$[27{,}98;\ 36{,}52)$	32,25	11	0,0940	16	0,1368
$[36{,}52;\ 45{,}07)$	40,80	29	0,2479	45	0,3846
$[45{,}07;\ 53{,}61)$	49,34	32	0,2735	77	0,6581
$[53{,}61;\ 62{,}16)$	57,89	30	0,2564	107	0,9145
$[62{,}16;\ 70{,}70)$	66,43	10	0,0855	117	1

3 Gráficos: cuál usar

Datos	Gráfico	Lo que muestra
Cualitativos	Barras / torta (pie)	Frecuencia de cada categoría. Barras *separadas*.
Discretos	Barras (bastones)	Frecuencia de cada valor; el eje x tiene orden.
Continuos agrupados	Histograma + polígono	Forma de la distribución. Barras *pegadas*.
Continuos agrupados	Ojiva (acumulado)	N_i o F_i contra el límite superior.
Pocos datos cuantitativos	Tallo y hoja	Forma + los datos exactos.
Dos variables numéricas	Dispersión	Relación entre X e Y (¿recta?).
Datos en el tiempo	Serie de tiempo	Tendencia y patrones (ej. semanales).



Cómo se construye cada uno

Polígono: une las marcas de clase a la altura n_i (y cierra en 0 en las clases vacías de los extremos). **Ojiva:** cada punto va en el *límite superior* de la clase con altura N_i, porque recién al final del intervalo ya conté todos sus datos. Parte en 0 en LI_1 y termina en n.

3.1 Diagrama de tallo y hoja

Útil con **pocos o moderados** datos cuantitativos: muestra la forma *sin perder los valores*. El **tallo** son los primeros dígitos y la **hoja** los restantes. El corte lo elijo según el detalle que quiero: 1548 → 15|48, 154|8 o 1|548.

Ejemplo mini (contaminación, 26 datos)

3	0 0 9
4	4
5	
6	1 1 4 4 8 9 9
7	1 4 5 8 8 9
8	0
9	4 7 8 9
10	2 7 8
11	
⋮	
17	6

Tallo = decenas, hoja = unidades (30 → 3|0, 176 → 17|6).

Girado, se ve como un histograma: la masa está entre 60 y 80, y el 176 queda solo, muy lejos: es un **dato atípico**.

Los tallos vacíos (5, 11, . . .) **se escriben igual**, para que las distancias se vean bien.

3.2 Dispersión y serie de tiempo

- **Dispersión:** un punto (x_i, y_i) por individuo. Ej.: renta vs. impuesto de 12 personas. Si los puntos siguen una recta, se puede ajustar la "mejor recta" (regresión, más adelante).
- **Serie de tiempo:** los datos en orden temporal, unidos con líneas. Ej.: pasajeros en la estación Valencia durante 3 semanas. Se ve una **tendencia** creciente y un **patrón semanal** (los sábados y domingos bajan). Una recta sola captura la tendencia pero no el patrón semanal.

4 Resumen para la prueba

Si me piden / veo…	Pienso en…
"¿Qué escala es?"	¿Solo clasifica? nominal. ¿Ordena? ordinal. ¿Tiene sentido restar? intervalar. ¿Existe un cero real? razón.
Columnas acumuladas en una variable nominal	Están mal: acumular exige orden.
Variable continua con muchos valores	Agrupar en intervalos (en la prueba la tabla viene dada; el algoritmo no se usa).
"Proporción con a lo más…"	Leer la columna F_i.
Pocos datos, quiero ver forma y valores	Tallo y hoja.
Datos ordenados en el tiempo	Serie de tiempo (tendencia y patrones).

Ojo

Barras de un gráfico de barras: **separadas** (categorías o valores puntuales). Histograma: **pegadas** (intervalos contiguos de una variable continua).