Hecho por Tomás Jarufe · tjarufe@usm.cl · https://tomasjarufe.site/

Inferencia I: Estimación Puntual

TLC, distribuciones de muestreo, momentos, máxima verosimilitud y propiedades

MAT 70725 · Probabilidad y Estadística · UTFSM · 2 de noviembre de 2026

En las unidades anteriores el modelo era conocido ($X \sim \text{Exp}(\theta)$ con θ dado) y calculaba probabilidades. Ahora conozco la forma *del modelo pero* ***no sus parámetros****: con los datos tengo que adivinar un valor plausible de θ (estimación) y ver qué tan bueno es ese valor (propiedades).*

1 Sucesiones y convergencia en distribución

Una **sucesión de v.a.** $X_1, X_2, \ldots$ (o $\{X_n\}_{n\geq 1}$) es una colección ordenada de v.a. No tienen por qué ser independientes ni tener la misma distribución. Ejemplo clave: la media $\overline{X}_n = \frac{1}{n}\sum_{j=1}^{n} X_j$ forma una sucesión, una variable distinta para cada n.

Convergencia en distribución

$X_n \xrightarrow{D} X$ si $\lim_{n\to\infty} F_{X_n}(x) = F_X(x)$ en todo x donde F_X es continua.

En palabras: para n grande, calculo probabilidades de X_n como si fuera X.

Ejemplo mini

$X_n \sim \text{Unif}(0, 1 + \frac{1}{n})$. La idea es **fijar** x **primero** y después hacer $n \to \infty$:

$$F_{X_n}(x) = \begin{cases} 0 & x < 0 \\ \dfrac{nx}{n+1} & 0 \leq x < 1 + \frac{1}{n} \\ 1 & x \geq 1 + \frac{1}{n} \end{cases} \xrightarrow[n\to\infty]{} \begin{cases} 0 & x < 0 \\ x & 0 \leq x < 1 = F_X(x) \\ 1 & x \geq 1 \end{cases}$$

- $0 \leq x < 1$: siempre estoy en el tramo del medio, y $\frac{nx}{n+1} \to x$.
- $x > 1$: el borde $1 + \frac{1}{n}$ baja hacia 1, así que desde algún n en adelante queda $x \geq 1 + \frac{1}{n}$ y $F_{X_n}(x) = 1$ (ej. $x = 1{,}05$: para $n \geq 20$ ya vale 1). En $x = 1$: $\frac{n}{n+1} \to 1$.

El límite es la acumulada de $X \sim \text{Unif}(0,1)$, así que $X_n \xrightarrow{D} \text{Unif}(0,1)$. Tiene sentido: el intervalo $(0, 1 + \frac{1}{n})$ se encoge hasta $(0,1)$.

¿Por qué "solo donde F_X es continua"?

En los saltos de F_X el límite puede fallar aunque la sucesión sí converja. Ej.: $X_n = \frac{1}{n}$ (constante) tiende claramente a $X = 0$, pero $F_{X_n}(0) = \mathbb{P}[\frac{1}{n} \leq 0] = 0$ y $F_X(0) = 1$. Solo falla justo en el salto, así que ese punto se excluye. En la Uniforme, F_X es continua en todos lados y no se excluye nada.

2 Teorema Central del Límite (TLC)

TLC

Si $X_1, X_2, \ldots$ son **i.i.d.** con $\mathbb{E}[X_j] = \mu$ y $\mathbb{V}[X_j] = \sigma^2$ finita, entonces

$$\frac{\sum_{j=1}^{n} X_j - n\mu}{\sigma\sqrt{n}} \xrightarrow{D} Z \sim N(0,1) \qquad \Longleftrightarrow \qquad \frac{\overline{X}_n - \mu}{\sigma/\sqrt{n}} \xrightarrow{D} Z$$

Para n grande: $\mathbb{P}\left[a \leq \dfrac{\overline{X}_n - \mu}{\sigma/\sqrt{n}} \leq b\right] \approx \Phi(b) - \Phi(a)$.

¿Por qué aparece la Normal aunque X no sea Normal?

Una suma de muchos efectos independientes suaviza las particularidades de cada uno: los valores altos y bajos se compensan y queda una forma de campana. Lo que importa de X es solo su media y su varianza. Estandarizo con $\sigma/\sqrt{n}$ porque esa es la desviación estándar de $\overline{X}_n$ (sección 3). La precisión de la aproximación depende de n y de la forma de X: si X es muy asimétrica, se necesita un n más grande.

Ejemplo mini (TLC)

Duración de componentes $\sim$ Exp con media 100 h ($\mu = 100$, $\sigma^2 = 100^2$), $n = 64$. ¿$\mathbb{P}[\overline{X} > 110]$?

$$\mathbb{P}[\overline{X} > 110] \approx \mathbb{P}\left[Z > \tfrac{110-100}{100/\sqrt{64}}\right] = 1 - \Phi(0{,}8) = 0{,}2119$$

El valor exacto (la suma de 64 exponenciales es Gamma) es 0,2072: el TLC aproxima bien.

3 Muestras, estadísticos y distribuciones de muestreo

Muestra aleatoria	$X_1, \ldots, X_n$ es m.a.$(n) \Leftrightarrow$ son **i.i.d.** (independientes y con la misma distribución que X).
Estadístico	Función de la muestra $T = T(X_1, \ldots, X_n)$ que **no depende de parámetros desconocidos**. Es una v.a.: mayúscula antes de observar (T) y minúscula ya observado (t). Ej.: $\sum X_j$, $\prod X_j$, S^2.
Parámetro θ	Número que describe la población. Θ es el espacio paramétrico (valores posibles de θ).
Estimador $\widehat{\theta}$	Estadístico elegido para estimar θ (es una v.a.).
Estimación	El número que da el estimador con los datos observados.
Dist. de muestreo	La distribución de un estadístico: cómo varía su valor de una muestra a otra.

Ojo

$\overline{X} - \mu$ **no** es un estadístico si μ es desconocido: depende del parámetro. En cambio $\overline{X}$ sí lo es.

Ejemplo mini (distribución de muestreo)

Lanzo una moneda dos veces, $Y =$ caras $-$ sellos: $\mathbb{P}[Y = -2] = \frac{1}{4}$, $\mathbb{P}[Y = 0] = \frac{1}{2}$, $\mathbb{P}[Y = 2] = \frac{1}{4}$. Con una m.a.(2) Y_1, Y_2, el estadístico $W = Y_1 Y_2$ toma los valores $\{-4, 0, 4\}$: $\mathbb{P}[W = 0] = 1 - \left(\frac{1}{2}\right)^2 = \frac{3}{4}$ (basta que uno sea 0), y $\mathbb{P}[W = 4] = \mathbb{P}[W = -4] = 2 \cdot \frac{1}{16} = \frac{1}{8}$. Su distribución sale de

la de Y.

3.1 Suma y media muestral

Para una m.a. con $\mathbb{E}[X]$ y $\mathbb{V}[X]$, con $T = \sum_{j=1}^{n} X_j$:

$$\mathbb{E}[T] = n\,\mathbb{E}[X], \quad \mathbb{V}[T] = n\,\mathbb{V}[X] \qquad\qquad \mathbb{E}[\overline{X}] = \mathbb{E}[X], \quad \mathbb{V}[\overline{X}] = \frac{\mathbb{V}[X]}{n}$$

¿Por qué la varianza de $\overline{X}$ baja como $1/n$?

Por independencia las varianzas se suman: $\mathbb{V}[T] = n\mathbb{V}[X]$. Como $\overline{X} = T/n$, sale $\mathbb{V}[\overline{X}] = n\mathbb{V}[X]/n^2 = \mathbb{V}[X]/n$. Promediar hace que los errores de cada dato se compensen: con más datos, $\overline{X}$ se concentra alrededor de μ.

Caso Normal (exacto, para todo n): si $X_j \sim N(\mu,\sigma^2)$, entonces $\overline{X} \sim N\left(\mu,\frac{\sigma^2}{n}\right)$ y $T \sim N(n\mu,n\sigma^2)$. Aquí no hay aproximación, a diferencia del TLC.

Ejemplo mini (eclisas)

Resistencia $\sim N(4{,}335;\, 0{,}6^2)$ t, muestra de $n = 35$. ¿$\mathbb{P}[\overline{X} \geq 4{,}3]$?

$$\mathbb{P}[\overline{X} \geq 4{,}3] = 1 - \Phi\left(\tfrac{4{,}3-4{,}335}{0{,}6/\sqrt{35}}\right) = 1 - \Phi(-0{,}35) = \Phi(0{,}35) = 0{,}6368$$

¿Qué n asegura $\mathbb{P}[\overline{X} > 4{,}3] \geq 0{,}95$? Necesito $\Phi\left(\frac{0{,}035\sqrt{n}}{0{,}6}\right) \geq 0{,}95$. En la tabla, $\Phi(1{,}64) = 0{,}9495 < 0{,}95$ y $\Phi(1{,}65) = 0{,}9505$, así que pido $\frac{0{,}035\sqrt{n}}{0{,}6} \geq 1{,}65$, o sea $\sqrt{n} \geq 28{,}29$ y $n \geq 800{,}1$. Resultado: $n = 801$ (con $z = 1{,}645$ da 796). Tiene sentido que sea enorme: 4,3 está muy cerca de la media 4,335.

3.2 Mínimo y máximo de la muestra

Estadísticos de orden: $X_{(1)} \leq \cdots \leq X_{(n)}$. Interesan $Y_1 = X_{(1)} = \min$ e $Y_n = X_{(n)} = \max$. Con X continua:

$$f_{Y_1}(y) = n\big(1 - F_X(y)\big)^{n-1} f_X(y) \qquad\qquad f_{Y_n}(y) = n\big(F_X(y)\big)^{n-1} f_X(y)$$

De dónde salen (por independencia)

Máximo: $\{Y_n \leq y\}$ = "*todos* los datos son $\leq y$", así que $F_{Y_n}(y) = F_X(y)^n$. **Mínimo:** $\{Y_1 > y\}$ = "todos son $> y$", así que $\mathbb{P}[Y_1 > y] = (1 - F_X(y))^n$ y $F_{Y_1} = 1 - (1 - F_X)^n$. Derivando (regla de la cadena) salen las densidades. En la práctica conviene **trabajar con la acumulada**, que es más fácil.

4 Técnicas de estimación

Métodos: momentos, máxima verosimilitud, mínima distancia, mínimos cuadrados (y otros como Bootstrap y EM). En este curso se usan los dos primeros.

4.1 Método de los momentos

"Lo observado = lo esperado": igualo los momentos teóricos (que dependen de θ) con los de la muestra y despejo θ.

Momentos y sistema

Muestral: $m_r = \frac{1}{n}\sum_{j=1}^{n} X_j^r$. Poblacional: $\mu_r = \mathbb{E}[X^r]$ (función de θ).

Con k parámetros, planteo $\mu_1 = m_1$, $\mu_2 = m_2$, $\ldots$, $\mu_k = m_k$ y resuelvo. El resultado es $(\widehat{\theta}_1, \ldots, \widehat{\theta}_k)$.

¿Por qué es razonable?

Por la sección 3, $\mathbb{E}[m_1] = \mathbb{E}[\overline{X}] = \mu_1$ y su varianza se va a 0: con muchos datos, el momento muestral queda pegado al teórico. Si los igualo, el θ que resuelve la ecuación debería estar cerca del verdadero.

Ejemplo mini (1 parámetro)

$f_X(x;\theta) = \frac{3\theta^3}{x^4}\mathbb{I}_{]\theta,\infty[}(x)$. $\mathbb{E}[X] = \int_\theta^\infty x\frac{3\theta^3}{x^4}dx = 3\theta^3\Big[-\frac{1}{2x^2}\Big]_\theta^\infty = \frac{3\theta}{2}$. Igualo $\frac{3\theta}{2} = \overline{X}$:

$$\widehat{\theta}_M = \tfrac{2}{3}\overline{X}$$

Ejemplo mini (2 parámetros: Gamma(α,β), $\mathbb{E} = \alpha\beta$, $\mathbb{V} = \alpha\beta^2$)

Uso $\mu_1 = \alpha\beta = m_1$ y $\mu_2 = \mathbb{V} + \mathbb{E}^2$, o sea $\alpha\beta^2 = m_2 - m_1^2 = \frac{1}{n}\sum(X_j - \overline{X})^2 =: \widehat{\sigma}^2$. Divido la 2.ª ecuación por la 1.ª:

$$\widehat{\beta}_M = \frac{\widehat{\sigma}^2}{\overline{X}}, \qquad \widehat{\alpha}_M = \frac{\overline{X}^2}{\widehat{\sigma}^2}$$

Ojo

Plantear $\mu_2 = m_2$ equivale a igualar la varianza teórica con $\frac{1}{n}\sum(X_j - \overline{X})^2$, que divide por n y **no** por $n-1$.

4.2 Método de máxima verosimilitud (EMV)

Elijo el θ que hace más probable *haber observado justo los datos que obtuve.*

Verosimilitud y EMV

$$L(\theta) = L(x_1, \ldots, x_n; \theta) = \prod_{j=1}^{n} f_X(x_j;\theta) \qquad \widehat{\theta}_{MV}: \; L(\widehat{\theta}_{MV}) = \sup_{\theta\in\Theta} L(\theta)$$

Es la conjunta de la muestra (producto, por independencia), vista como **función de** θ con los datos fijos.

Receta (caso "suave"):

1. Escribir $L(\theta) = \prod f(x_j;\theta)$, **incluyendo la indicatriz**.
2. Tomar $\ell(\theta) = \ln L(\theta)$ (el producto se vuelve suma; como ln es creciente, el máximo está en el mismo θ).
3. Resolver $\ell'(\theta) = 0$ y verificar que es máximo ($\ell'' < 0$).

Ejemplo mini (Exponencial)

$f = \theta e^{-\theta x}$, $x > 0$. $L = \theta^n e^{-\theta \sum x_j}$, $\ell = n \ln \theta - \theta \sum x_j$, $\ell' = \frac{n}{\theta} - \sum x_j = 0$:

$$\widehat{\theta}_{MV} = \frac{1}{\overline{X}} \qquad (\ell'' = -n/\theta^2 < 0 \checkmark)$$

Tiene sentido: $\mathbb{E}[X] = 1/\theta$, así que si en promedio espero $\overline{X}$, la tasa es $1/\overline{X}$.

Ejemplo mini (Bernoulli)

$f = p^x (1-p)^{1-x}$. $\ell = \left(\sum x_j\right) \ln p + \left(n - \sum x_j\right) \ln(1-p)$, $\ell' = \dfrac{\sum x_j}{p} - \dfrac{n - \sum x_j}{1-p} = 0 \Rightarrow \widehat{p}_{MV} = \overline{X}$ (la proporción de éxitos observada).

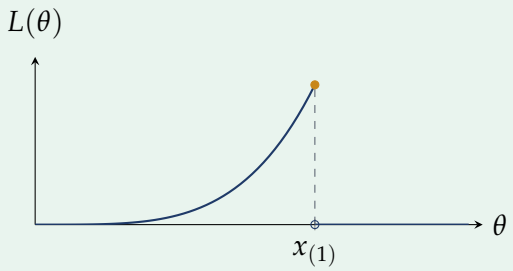
Caso "con borde": cuando el soporte depende de θ, la derivada no sirve y hay que mirar la indicatriz.

Ejemplo mini ($f = 3\theta^3 x^{-4}$, $x > \theta$)

$$L(\theta) = 3^n \theta^{3n} \prod x_j^{-4} \cdot \mathbb{I}\left(\theta < x_{(1)}\right)$$

porque *todos* los $x_j > \theta$ equivale a $\min x_j > \theta$. L crece con θ (por el θ^{3n}), pero se anula en cuanto θ pasa $x_{(1)}$. El máximo está en el borde:

$$\widehat{\theta}_{MV} = X_{(1)}$$



Ojo

Si θ aparece en el **soporte** (dentro de la indicatriz), **no derivo**: dibujo $L(\theta)$ y busco el borde. Igual pasa con Unif(0,θ): $L = \theta^{-n}\, \mathbb{I}(\theta \geq x_{(n)})$ decrece en θ, así que $\widehat{\theta}_{MV} = X_{(n)}$.

Resultado de la Normal (desafío de clase): $\widehat{\mu}_{MV} = \overline{X}$, $\widehat{\sigma^2}_{MV} = \frac{1}{n}\sum (X_j - \overline{X})^2$.

Invarianza del EMV

Si $\widehat{\theta}_{MV}$ es el EMV de θ y g es continua e inyectiva, entonces $\widehat{g(\theta)}_{MV} = g(\widehat{\theta}_{MV})$.

Ejemplo mini

En la Exponencial, la media es $1/\theta$, así que su EMV es $1/\widehat{\theta}_{MV} = \overline{X}$. Y $\widehat{\sigma}_{MV} = \sqrt{\widehat{\sigma^2}_{MV}}$.

5 Propiedades de los estimadores

Para comparar estimadores pregunto: ¿le apunta al blanco en promedio? (sesgo) ¿Qué tan disperso es? (varianza) ¿Mejora con más datos? (consistencia).

Insesgado	$\mathbb{E}[\widehat{\theta}] = \theta$	En promedio sobre todas las muestras, acierta. Si no: $\text{Sesgo}(\widehat{\theta}) = \mathbb{E}[\widehat{\theta}] - \theta$.
ECM	$\mathbb{E}\left[(\widehat{\theta} - \theta)^2\right] = \mathbb{V}[\widehat{\theta}] + \text{Sesgo}(\widehat{\theta})^2$	Error total: dispersión + desvío sistemático.
Consistente (ECM)	$\lim_{n\to\infty} \text{ECM}(\widehat{\theta}) = 0$	Con más datos, se pega al valor verdadero.
Más eficiente	$\text{ECM}(\widehat{\theta}_1) < \text{ECM}(\widehat{\theta}_2)$	Equivale a $\text{ECM}_1/\text{ECM}_2 < 1$: comete menos error.

ECM = varianza + sesgo^2

Sumo y resto $\mathbb{E}[\widehat{\theta}]$: $\widehat{\theta} - \theta = \left(\widehat{\theta} - \mathbb{E}[\widehat{\theta}]\right) + \left(\mathbb{E}[\widehat{\theta}] - \theta\right)$. Al elevar al cuadrado y tomar esperanza, el término cruzado vale 0 porque $\mathbb{E}\left[\widehat{\theta} - \mathbb{E}[\widehat{\theta}]\right] = 0$. Queda $\mathbb{V}[\widehat{\theta}] + \text{Sesgo}^2$. Para un insesgado, ECM $= \mathbb{V}$, así que comparar eficiencia es comparar varianzas.

Ojo

Para ser consistente basta que **varianza y sesgo se vayan a 0** cuando $n \to \infty$. Un estimador sesgado puede ser consistente si su sesgo desaparece con n. Uno con sesgo fijo nunca lo es.

5.1 Ejemplos de clase, resueltos corto

(1) Bernoulli, $\widehat{p} = \overline{X}$. $\mathbb{E}[\overline{X}] = p$ (insesgado), $\mathbb{V}[\overline{X}] = \frac{p(1-p)}{n} \to 0$, así que ECM $\to 0$: consistente.

(2) Normal. $\mathbb{E}[\overline{X}] = \mu$: insesgado. Pero $\mathbb{E}\left[\frac{1}{n}\sum(X_j - \overline{X})^2\right] = \frac{n-1}{n}\sigma^2 \neq \sigma^2$: **sesgado**. Para corregirlo multiplico por $\frac{n}{n-1}$:

$$S^2 = \frac{1}{n-1}\sum_{j=1}^{n}(X_j - \overline{X})^2 \quad \text{es insesgado para } \sigma^2$$

Esta es la razón del $n-1$ en la varianza muestral: al usar $\overline{X}$ en vez de μ, las desviaciones quedan un poco más chicas de lo real, y dividir por $n-1$ lo compensa. El sesgo $-\sigma^2/n \to 0$, así que el EMV igual es consistente.

(3) $f = 3\theta^3 x^{-4}$, $x > \theta$**: dos estimadores insesgados.**

- Con $\overline{X}$: $\mathbb{E}[\overline{X}] = \frac{3}{2}\theta \Rightarrow T_1 = \frac{2}{3}\overline{X}$ es insesgado. Con $\mathbb{E}[X^2] = 3\theta^2$ se obtiene $\mathbb{V}[X] = \frac{3}{4}\theta^2$, y entonces $\mathbb{V}[T_1] = \frac{4}{9}\cdot\frac{3\theta^2}{4n} = \dfrac{\theta^2}{3n}$.
- Con $X_{(1)}$: $\mathbb{P}[X > y] = (\theta/y)^3$, así que $\mathbb{P}[X_{(1)} > y] = (\theta/y)^{3n}$ (la misma forma con exponente $3n$). Entonces $\mathbb{E}[X_{(1)}] = \frac{3n}{3n-1}\theta$ y $T_2 = \frac{3n-1}{3n}X_{(1)}$ es insesgado, con $\mathbb{V}[T_2] = \dfrac{\theta^2}{3n(3n-2)}$.

$$\frac{\text{ECM}(T_2)}{\text{ECM}(T_1)} = \frac{1}{3n-2} < 1 \ \ (n \geq 2) \quad \Rightarrow \quad T_2 \text{ (basado en el mínimo) es más eficiente.}$$

Tiene sentido: θ es el borde inferior del soporte, y el mínimo de la muestra es el dato que más información da sobre dónde está ese borde.

(4) Unif$(\theta,\theta+1)$, $\widehat{\theta}=\overline{X}$. $\mathbb{E}[\overline{X}]=\theta+\frac{1}{2}$: sesgo $\frac{1}{2}$. ECM $=\frac{1}{12n}+\frac{1}{4}\to\frac{1}{4}\neq 0$: **no es consistente**. El sesgo es fijo y no desaparece con más datos. Se arregla con $\widehat{\theta}=\overline{X}-\frac{1}{2}$: insesgado, con ECM $=\frac{1}{12n}\to 0$.

6 Resumen para la prueba

Si el enunciado dice...	Pienso en...
Promedio de muchas v.a. i.i.d. no normales, n grande	TLC: estandarizar con $\sigma/\sqrt{n}$ y leer Φ
Promedio de normales	$\overline{X}\sim N(\mu,\sigma^2/n)$, exacto
"¿Qué n necesito para que...?"	Despejar $\sqrt{n}$ desde z (de la tabla, redondeando hacia el lado seguro)
Mínimo o máximo de la muestra	Partir de $\mathbb{P}[Y_1>y]=(1-F)^n$ o de $F_{Y_n}=F^n$
"Estimador de momentos"	$\mathbb{E}[X^r]=\frac{1}{n}\sum X_j^r$, tantas ecuaciones como parámetros
"EMV"	$L=\prod f$, luego ln, derivar e igualar a 0; si θ está en el soporte: **borde** ($X_{(1)}$ o $X_{(n)}$)
EMV de una función de θ	Invarianza: $g(\widehat{\theta}_{MV})$
"¿Es insesgado?"	Calcular $\mathbb{E}[\widehat{\theta}]$ y comparar con θ; si da $c\,\theta$, divido por c
"¿Es consistente?"	ECM $=\mathbb{V}+\text{Sesgo}^2\to 0$
"¿Cuál es más eficiente?"	El de menor ECM (si ambos son insesgados: menor varianza)

Ojo

(1) El TLC pide i.i.d. y varianza finita, y es una *aproximación*. Con datos normales el resultado es exacto. (2) En $N(\mu,\sigma^2)$ el segundo parámetro es la **varianza**: al estandarizar uso $\sigma/\sqrt{n}$, no σ^2/n. (3) En el EMV, nunca olvidar la indicatriz. (4) Un estadístico no puede contener parámetros desconocidos.