Hecho por Tomás Jarufe · tjarufe@usm.cl · https://tomasjarufe.site/

Estadística Descriptiva II

Medidas de localización, dispersión, forma y box-plot

MAT 70725 · Probabilidad y Estadística · UTFSM · 1 de noviembre de 2026

> *Una tabla o un gráfico muestran* todo. *Un indicador resume los datos en* un número*: dónde está el centro (localización), cuánto se alejan del centro (dispersión), qué forma tiene la distribución (asimetría, curtosis) y comparaciones relativas (CV).*

Notación. n datos; en datos agrupados: k clases, n_j, $f_j = n_j/n$, N_j acumulada, m_j marca de clase (punto medio), LI límite inferior y a amplitud de la clase.

1 Variable cualitativa: moda y variación modal

Moda y variación modal

Moda (Mo): la categoría más frecuente (es un índice de *concentración*). $\quad V_{Mo} = 1 - f_{Mo}$

¿Qué mide V_{Mo}?

Es la proporción de datos que *no* son la moda. Si $V_{Mo} \approx 0$, casi todos están en la moda y esta representa bien los datos. Si V_{Mo} es grande, la moda es poco representativa.

Ejemplo mini

Forma de pago de 42 usuarios: Efectivo 6, PAC 8, PAT 18, Prepago 10. $Mo =$ PAT, $V_{Mo} = 1 - \frac{18}{42} = 0{,}5714$: el 57 % *no* paga con PAT, así que la moda representa a menos de la mitad.

2 Localización

2.1 Cuantiles y percentiles

El percentil P_ℓ es el valor que deja el ℓ % de los datos a su izquierda. Todo cuantil es un percentil:

Cuartiles Q_1,Q_2,Q_3	Quintiles $K_1,\ldots,K_4$	Deciles $D_1,\ldots,D_9$
$Q_1 = P_{25}$, $Q_3 = P_{75}$	$K_1 = P_{20}$, $K_4 = P_{80}$	$D_1 = P_{10}$, $D_9 = P_{90}$

$$P_{50} = Q_2 = D_5 = \textbf{Mediana}$$

Estadísticos de orden: los datos ordenados de menor a mayor, $X_{(1)} \le X_{(2)} \le \cdots \le X_{(n)}$. $X_{(k)}$ es el k-ésimo menor valor.

Percentil, datos dispersos (no agrupados)

$$P_\ell = X_{(h)}, \qquad h = 1 + \frac{\ell\,(n-1)}{100} \quad \text{(posición en la muestra ordenada)}$$

Si h es entero, tomo ese dato. Si no, **pondero los dos vecinos**: con $h = i{,}d$ (parte entera i, decimal d),

$$P_\ell = (1-d)\,X_{(i)} + d\,X_{(i+1)} \qquad \text{ej. } h = 15{,}16 \Rightarrow P = 0{,}84\,X_{(15)} + 0{,}16\,X_{(16)}$$

¿Por qué $h = 1 + \ell(n-1)/100$?

Entre el primer dato ($h = 1$) y el último ($h = n$) hay $n - 1$ "saltos". Recorro el ℓ % de esos saltos partiendo del primero. $\ell = 0$ da el mínimo, $\ell = 100$ el máximo y $\ell = 50$ da $h = \frac{n+1}{2}$, que es justo la posición de la mediana. La ponderación es interpolar linealmente: mientras más cerca estoy de $X_{(i+1)}$ (mayor d), más pesa ese dato.

Ejemplo mini

25 datos ordenados, $X_{(15)} = 10{,}12$, $X_{(16)} = 10{,}23$. P_{59}: $h = 1 + \frac{59 \cdot 24}{100} = 15{,}16 \Rightarrow P_{59} = 0{,}84(10{,}12) + 0{,}16(10{,}23) = 10{,}1376$.

Percentil interpolado, datos agrupados

Primero ubico la **clase percentil** CP: la primera con $N_j \geq n\ell/100$. Luego

$$P_\ell = LI_{CP} + \left(n \cdot \frac{\ell}{100} - N_{CP-1}\right) \frac{a_{CP}}{n_{CP}}$$

¿Por qué tiene esa forma?

Se supone que los datos están **repartidos uniformemente** dentro de la clase. Necesito llegar a $n\ell/100$ datos. Hasta el inicio de la clase llevo N_{CP-1}, así que me faltan $\left(n\ell/100 - N_{CP-1}\right)$. Cada dato de la clase "ocupa" un ancho a_{CP}/n_{CP}. Entonces avanzo (datos que faltan)$\times$(ancho por dato) desde LI_{CP}.

Para los ejemplos uso la tabla de tiempos de espera ($n = 117$) de la parte 1:

Clase	$[10{,}89; 19{,}43)$	$[19{,}43; 27{,}98)$	$[27{,}98; 36{,}52)$	$[36{,}52; 45{,}07)$	$[45{,}07; 53{,}61)$	$[53{,}61; 62{,}16)$	$[62{,}16; 70{,}70)$
n_j	1	4	11	29	32	30	10
N_j	1	5	16	45	77	107	117

Ejemplo mini (P_{80} y "más de 55 s")

P_{80}: $117 \cdot 0{,}8 = 93{,}6$. Como $N_5 = 77 < 93{,}6 \leq N_6 = 107$, la clase percentil es la 6.ª:

$$P_{80} = 53{,}61 + (93{,}6 - 77)\tfrac{8{,}55}{30} = 58{,}341 \text{ s}$$

El 80 % de los clientes espera a lo más 58,3 s.

Al revés (dado el valor, busco ℓ): $55 = 53{,}61 + \left(117\frac{\ell}{100} - 77\right)\frac{8{,}55}{30} \Rightarrow \ell \approx 69{,}98$. Por lo tanto, espera *más* de 55 s el $100 - 69{,}98 = 30{,}02$ %.

2.2 Media, mediana y moda

	Datos dispersos	Datos agrupados
Media	$\overline{X} = \frac{1}{n}\sum_{j=1}^{n} X_j$	$\overline{X} = \sum_{j=1}^{k} f_j m_j = \frac{1}{n}\sum_{j=1}^{k} n_j m_j$
Mediana	$Me = X_{(\frac{n+1}{2})}$ (ordenar antes; si $\frac{n+1}{2}$ no es entero, promediar los dos centrales)	$Me = LI_{CMe} + \left(\frac{n}{2} - N_{CMe-1}\right)\frac{a_{CMe}}{n_{CMe}}$
Moda	El valor más frecuente	$Mo = LI_{CMo} + \frac{d_1}{d_1 + d_2} a_{CMo}$

con $d_1 = n_{CMo} - n_{CMo-1}$ y $d_2 = n_{CMo} - n_{CMo+1}$ (diferencia con la clase anterior y con la siguiente). La mediana agrupada es el percentil interpolado con $\ell = 50$.

Moda interpolada: ¿por qué $d_1/(d_1+d_2)$?

La moda se corre dentro de la clase modal hacia el vecino más alto. Si la clase anterior es casi tan alta como la modal (d_1 chico), la moda queda cerca del borde izquierdo. Si $d_1 = d_2$, queda justo al centro.

Ejemplo mini (tiempos agrupados)

$\overline{X} = \sum f_j m_j = 48{,}10$. *Me*: $n/2 = 58{,}5$, clase 5: $45{,}07 + (58{,}5 - 45)\frac{8{,}54}{32} = 48{,}67$. *Mo*: clase 5, $d_1 = 32 - 29 = 3$, $d_2 = 32 - 30 = 2$: $45{,}07 + \frac{3}{5}\,8{,}54 = 50{,}19$.

Ojo

La media se deja arrastrar por los datos extremos; la mediana no (solo depende del orden). Con un dato atípico grande, $\overline{X}$ sube y *Me* casi no cambia.

3 Dispersión

Miden cuánto se alejan los datos del centro (riesgo, precisión). Dos muestras pueden tener la misma media y una dispersión muy distinta.

	Datos dispersos	Datos agrupados
Rango	$R = \max\{x_i\} - \min\{x_i\}$	$R = LS_k - LI_1$
Desv. absoluta	$DA(TC) = \frac{1}{n}\sum_{i=1}^{n} \lvert X_i - TC\rvert$	$DA(TC) = \sum_{i=1}^{k} f_i \lvert m_i - TC\rvert$
Varianza	$S^2 = \frac{1}{n-1}\sum_{j=1}^{n}(X_j - \overline{X})^2$ $= \frac{1}{n-1}\left(\sum_{j=1}^{n} X_j^2 - n\overline{X}^2\right)$	$S^2 = \sum_{j=1}^{k} f_j(m_j - \overline{X})^2$ $= \sum_{j=1}^{k} f_j m_j^2 - \overline{X}^2$
Desv. estándar	$S = \sqrt{S^2}$ (mismas unidades que los datos)	

Rango modificado (el rango del $b\,\%$ central): $R_{Mod}(b\%) = P_{\frac{100+b}{2}} - P_{\frac{100-b}{2}}$.

$b = 50$	Rango intercuartil	$RIQ = Q_3 - Q_1$
$b = 60$	Rango interquintil	$RIK = K_4 - K_1$
$b = 80$	Rango percentil	$RP = P_{90} - P_{10}$

¿Para qué el rango modificado?

El rango usa solo los dos datos más extremos: un atípico lo dispara. En clase: dos muestras con el mismo $RIQ = 3{,}724$ y $R_{Mod}(90\%) = 10{,}088$, pero $R = 16{,}893$ en una y $R = 129{,}137$ en la otra (un solo dato atípico). Cortar las colas hace la medida **robusta**.

Desviación absoluta y varianza

TC es un indicador de tendencia central. La DA es la distancia promedio al centro. El TC que la hace mínima es la **mediana**, por eso se recomienda la *desviación absoluta mediana*. La varianza promedia distancias *al cuadrado*: castiga más los datos lejanos y queda en unidades^2. Por eso se reporta S.

Ojo

En las diapositivas, la varianza de **datos dispersos divide por** $n-1$, pero la de **datos agrupados usa** $f_j = n_j/n$, o sea, divide por n. Es la convención del curso (y la que usa R en los ejemplos: $S = 10{,}9615$ para los tiempos sale con n). Uso cada fórmula en su caso.

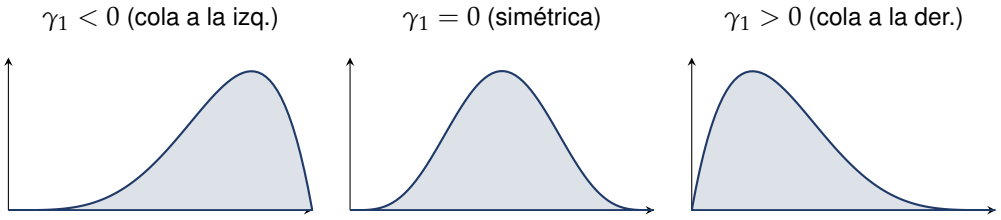
4 Forma: asimetría y curtosis

Usan los momentos centrados de orden 3 y 4 (en ambos se divide por n):

$$m_r = \frac{1}{n}\sum_{j=1}^{n}(X_j - \overline{X})^r \text{ (dispersos)}, \qquad m_r = \sum_{j=1}^{k} f_j (m_j - \overline{X})^r \text{ (agrupados)}$$

Coeficientes de Fisher (s = desviación estándar muestral)

$$\gamma_1 = \frac{m_3}{s^3} \text{ (asimetría o sesgo)} \qquad \gamma_2 = \frac{m_4}{s^4} - 3 \text{ (curtosis)}$$



¿Por qué el signo de m_3 indica hacia dónde va la cola?

Al cubo, las desviaciones *mantienen el signo* y las grandes pesan muchísimo. Si hay una cola larga a la derecha, esos pocos datos muy por encima de $\overline{X}$ dominan la suma: $m_3 > 0$. Dividir por s^3 lo deja sin unidades. En la curtosis, m_4/s^4 vale 3 para la Normal; el -3 la toma como referencia (Normal $\Rightarrow \gamma_2 = 0$).

$\gamma_1 > 0$	Asimétrica positiva (a la derecha): cola larga hacia valores altos.
$\gamma_1 < 0$	Asimétrica negativa (a la izquierda): cola larga hacia valores bajos.
$\gamma_1 = 0$	No hay evidencia de asimetría. (Simétrica $\Rightarrow \gamma_1 = 0$, pero **no al revés**.)

$\gamma_2 > 0$	**Leptocúrtica**: más curtosis que la Normal (más apuntada, colas pesadas).
$\gamma_2 = 0$	**Mesocúrtica**: como la Normal.
$\gamma_2 < 0$	**Platicúrtica**: menos curtosis que la Normal (más achatada).

Un γ_2 lejos de 0 puede deberse a: variabilidad excesiva o muy poca respecto a "lo ideal", **datos extremos** o **estratos** (subpoblaciones mezcladas). Ej. de clase: $\gamma_1 = 0{,}04$, $\gamma_2 = -0{,}01$ (casi normal) frente a $\gamma_1 = 7{,}47$, $\gamma_2 = 56{,}7$ (un atípico enorme).

Los datos vienen de algún modelo de probabilidad, así que una muestra grande refleja la forma de la densidad que la generó. En clase se simularon 200 datos de tres densidades Beta (cola a la izquierda, simétrica, cola a la derecha), y cada histograma copió la forma de su densidad.

5 Comparativo: coeficiente de variación

$$CV = \frac{S}{\overline{X}}$$

¿Por qué dividir por la media?

S tiene unidades y depende de la escala: una desviación de 10 s es mucha si la media es 20 s y poca si es 400 s. CV es la dispersión *relativa* al tamaño de los datos y no tiene unidades. Sirve para comparar conjuntos con escalas o unidades distintas: a mayor CV, mayor variabilidad relativa.

6 Box-plot (caja y bigotes)

Construcción

1. Calcular Q_1, $Q_2 = Me$, Q_3 y $RIQ = Q_3 - Q_1$.
2. **Fronteras interiores:** $FII = Q_1 - 1{,}5\,RIQ, \quad FIS = Q_3 + 1{,}5\,RIQ$.
3. **Bigotes:** $BI = \min\{x_i \in [FII, Q_1]\}, \quad BS = \max\{x_i \in [Q_3, FIS]\}$ (llegan hasta el dato real más extremo *dentro* de las fronteras).
4. **Atípicos:** los datos fuera de $[FII, FIS]$, dibujados como puntos.

Ojo

Los bigotes **no** llegan a FII ni a FIS: terminan en un *dato*. Las fronteras no se dibujan, solo sirven para decidir qué es atípico. Si no hay atípicos, los bigotes van del mínimo al máximo.

Lectura rápida: la caja contiene el 50 % central de los datos. Si la mediana está corrida dentro de la caja o un bigote es mucho más largo que el otro, hay asimetría. Con varios box-plots lado a lado (ej. gigas por ocupación o por empresa) comparo grupos.

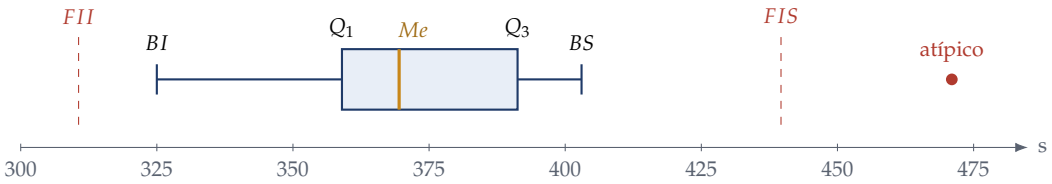
7 Ejemplo completo: simulacro de evacuación

Tiempos (s) de 26 trabajadores en ponerse a salvo:
389 356 359 363 375 471 325 394 402 373 373 370 364 366 364 325 339 393 392 369 374 359 356 403 334 397

Ordenados: $X_{(1)} = 325$, $X_{(2)} = 325, \ldots, X_{(25)} = 403$, $X_{(26)} = 471$. Además $\sum x = 9685$, $\sum x^2 = 3\,629\,631$, $m_3 = 28\,060{,}5$, $m_4 = 4\,253\,798{,}56$.

Medida	Cálculo	Lectura
$\overline{X}$	$9685/26 = 372{,}5$	tiempo promedio
Me	$h = 13{,}5$: $\frac{369+370}{2} = 369{,}5$	la mitad tarda $\leq 369{,}5$ s
Q_1	$h = 1 + \frac{25\cdot 25}{100} = 7{,}25$: $0{,}75 \cdot 359 + 0{,}25 \cdot 359 = 359$	
Q_3	$h = 19{,}75$: $0{,}25 \cdot 389 + 0{,}75 \cdot 392 = 391{,}25$	$RIQ = 32{,}25$
S	$\sqrt{\frac{1}{25}\left(3\,629\,631 - 26 \cdot 372{,}5^2\right)} = 29{,}64$	
CV	$29{,}64/372{,}5 = 0{,}0796$	poca variabilidad relativa (8 %)
γ_1	$28\,060{,}5/29{,}64^3 = 1{,}077$	cola a la derecha (el 471)
γ_2	$4\,253\,798{,}56/29{,}64^4 - 3 = 2{,}509$	leptocúrtica: el 471 pesa

Box-plot: $FII = 359 - 1{,}5(32{,}25) = 310{,}63$ y $FIS = 391{,}25 + 48{,}38 = 439{,}63$. Ningún dato bajo $FII \Rightarrow BI = 325$. Sobre FIS solo está el 471, así que **471 es atípico** y $BS = 403$.



Pregunta de clase: corre "peligro de muerte" quien demora más que $\overline{X} + \frac{3}{4}S = 372{,}5 + 0{,}75(29{,}64) = 394{,}73$ s. Los datos mayores son 397, 402, 403 y 471:

$$\text{proporción en peligro} = \frac{4}{26} = 0{,}1538$$

Tiene sentido: el umbral queda apenas sobre $Q_3 = 391{,}25$, así que debería caer algo menos del 25 % de los datos por encima.

Ejemplo mini (comparar con CV)

Simulacro: $CV = 0{,}0796$. Tiempos de espera telefónica: $\overline{X} = 48{,}10$, $S = 10{,}96$, $CV = 0{,}2279$. Aunque S es mayor en el simulacro (29,6 vs 11,0), en términos *relativos* los tiempos de espera son casi 3 veces más variables.

8 Resumen para la prueba

Si me piden...	Uso...
Variable cualitativa	Moda y $V_{Mo} = 1 - f_{Mo}$
Percentil con datos sueltos	Ordenar, $h = 1 + \ell(n-1)/100$, interpolar vecinos
Percentil / mediana con tabla	Ubicar la clase con $N_j \geq n\ell/100$ y aplicar la fórmula interpolada
"¿Qué % está sobre (o bajo) el valor x?"	Percentil al revés: despejar ℓ (y si es "sobre", $100 - \ell$)
Centro robusto ante atípicos	Mediana; dispersión robusta: RIQ
Comparar variabilidad entre escalas distintas	$CV = S/\overline{X}$
Hacia dónde está la cola	Signo de γ_1
¿Hay atípicos?	Box-plot: fuera de $[Q_1 - 1{,}5RIQ,\ Q_3 + 1{,}5RIQ]$

Ojo

(1) Antes de calcular cualquier cuantil, **ordenar** los datos. (2) S^2 divide por $n-1$ con datos dispersos y por n con datos agrupados. (3) Los momentos m_3 y m_4 dividen por n; en γ_1 y γ_2, s es la desviación *muestral*. (4) En la moda interpolada, d_1 y d_2 son diferencias de n_j, no de límites.