

Mis apuntes intuitivos

Esperanza, varianza, covarianza, correlación y esperanza iterada

Hecho por Tomás Jarufe

0. La imagen de fondo: probabilidad como arena

Una distribución es un montón de **arena** repartida sobre los valores posibles. En total hay exactamente 1 kilo. La probabilidad de un evento es *cuánta arena hay* en esa zona.

- Discreto: la arena está en montoncitos sobre puntos ($f_X(x)$ = peso del montón en x).
- Continuo: la arena está esparcida; $f_X(x)$ es la *altura* de la capa (densidad), y la cantidad en un tramo es el área: $\int f_X(x) dx$.
- Dos variables: la arena está sobre un *plano*, y $f_{X,Y}(x,y)$ es la altura (o el peso) del montón en cada punto (x,y) .

Todo lo que sigue son formas de **resumir** ese montón de arena con pocos números.

El ejemplo que uso en todo el documento


Un supermercado tiene dos cajas: una **tradicional** y una **rápida**. En un instante cualquiera del día miro las dos filas y anoto:

- X = número de clientes en la fila de la caja **tradicional** (puede ser 0, 1, 2, 3 o 4),
- Y = número de clientes en la fila de la caja **rápida** (puede ser 0, 1, 2 o 3).

La probabilidad de cada combinación (x,y) , es decir la función de cuantía conjunta $f_{X,Y}(x,y) = P[X = x, Y = y]$, es:

$X \backslash Y$	0	1	2	3	$f_X(x)$
0	0,08	0,07	0,04	0	0,19
1	0,06	0,15	0,05	0,04	0,30
2	0,05	0,04	0,10	0,06	0,25
3	0	0,03	0,04	0,07	0,14
4	0	0,01	0,05	0,06	0,12
$f_Y(y)$	0,19	0,30	0,28	0,23	1


Por ejemplo, la probabilidad de que haya 1 cliente en cada fila es $f_{X,Y}(1,1) = 0,15$. En el dibujo, cada burbuja es un montón de arena; su tamaño es su probabilidad.



1. Esperanza: el punto de equilibrio

La idea en una frase

$\mathbb{E}[X]$ es el punto donde la regla con la arena encima **quedaría en equilibrio**. También es el promedio que obtendrías si repitieras el experimento muchísimas veces.



Por qué se multiplica valor por probabilidad: en la ley de la palanca, cada peso tira con fuerza proporcional a *cuánto pesa* y a *dónde está*. Un valor muy probable “tira” más el punto de equilibrio hacia él. Por eso

$$\mathbb{E}[X] = \sum_x x f_X(x) \quad \text{o} \quad \mathbb{E}[X] = \int x f_X(x) dx.$$

En el ejemplo

$$\mathbb{E}[X] = 0 \cdot 0,19 + 1 \cdot 0,30 + 2 \cdot 0,25 + 3 \cdot 0,14 + 4 \cdot 0,12 = 1,70 \quad \text{y} \quad \mathbb{E}[Y] = 1 \cdot 0,30 + 2 \cdot 0,28 + 3 \cdot 0,23 = 1,55.$$

Esperanza de una función: $\mathbb{E}[g(X)] = \sum_x g(x) f_X(x)$. Se multiplica *lo que estás promediando* ($g(x)$) por el peso del montón ($f_X(x)$). En $\mathbb{E}[X]$ aparece x multiplicando sólo porque ahí $g(x) = x$.

Sumas: $\mathbb{E}[X + Y] = \mathbb{E}[X] + \mathbb{E}[Y]$ *siempre*. El promedio del total de clientes es el promedio de una fila más el de la otra, se relacionen como se relacionen. Sumar no mezcla nada.

Ojo

$\mathbb{E}[X]$ no tiene por qué ser un valor posible: nunca hay 1,70 clientes. Es el *centro*, no un resultado típico.

Cómo aparece en los ejercicios

“¿Cuánto se espera que...?”, “tiempo/número/valor esperado”, “en promedio”.

2. Varianza: qué tan desparramada está la arena

La idea en una frase

$\mathbb{V}[X]$ es el **promedio de las distancias al centro, al cuadrado**. Arena concentrada cerca de $\mathbb{E}[X] \Rightarrow$ varianza chica; arena desparramada $\Rightarrow$ varianza grande.

$$\mathbb{V}[X] = \mathbb{E}[(X - \mathbb{E}[X])^2]$$

¿Por qué al cuadrado? Si promediaras las distancias con signo, las de un lado se cancelarían con las del otro y siempre daría 0 (justamente porque $\mathbb{E}[X]$ es el punto de equilibrio). Al elevar al cuadrado todas cuentan positivo, y las desviaciones grandes pesan mucho más que las chicas.

Desviación estándar $\sigma_X = \sqrt{\mathbb{V}[X]}$: la varianza queda en “clientes al cuadrado”; la raíz la devuelve a las unidades originales. σ_X es, a grandes rasgos, la distancia típica al centro.

La fórmula práctica es el teorema de Steiner. Para quien viene de física:

$$\underbrace{\mathbb{E}[X^2]}_{\text{inercia respecto al 0}} = \underbrace{\mathbb{V}[X]}_{\text{inercia respecto al centro}} + \underbrace{\mathbb{E}[X]^2}_{\text{traslado del eje}} \implies \mathbb{V}[X] = \mathbb{E}[X^2] - \mathbb{E}[X]^2.$$

La varianza es literalmente el *momento de inercia* de la arena respecto a su centro de masa.

Transformaciones lineales: $\mathbb{V}[aX + b] = a^2 \mathbb{V}[X]$.

- $+b$ desplaza toda la arena junta: la forma del montón no cambia, la dispersión tampoco.
- $\times a$ estira el eje: todas las distancias se multiplican por a , y como la varianza promedia distancias *al cuadrado*, se multiplica por a^2 .

En el ejemplo

$\mathbb{E}[X^2] = 1 \cdot 0,30 + 4 \cdot 0,25 + 9 \cdot 0,14 + 16 \cdot 0,12 = 4,48$, $\mathbb{V}[X] = 4,48 - 1,70^2 = 1,59$, $\sigma_X \approx 1,26$ clientes.

Del mismo modo: $\mathbb{E}[Y^2] = 3,49$, $\mathbb{V}[Y] = 3,49 - 1,55^2 = 1,0875$.

Cómo aparece en los ejercicios

“Determine su varianza / desviación estándar”, “variabilidad”. Si piden la varianza de algo como $aX + b$, no se calcula de nuevo: se usa $a^2 \mathbb{V}[X]$.

3. Dos variables: aplastar y rebanar

Marginal = aplastar. Si empujas toda la arena del plano contra un eje, lo que queda apilado sobre ese eje es la marginal. En una tabla: sumar filas o columnas (son los totales de la tabla del ejemplo). En continuo: integrar la otra variable. Por eso en $f_X(x)$ *nunca* puede quedar una y : la aplastaste.

Condicional = rebanar y re-escalar. Saber que $Y = 1$ es quedarte sólo con la columna $Y = 1$ y tirar el resto. Esa rebanada pesa $f_Y(1)$, no 1 kilo; para que vuelva a ser una distribución la divides por su peso:

$$f_{X/Y=y}(x) = \frac{f_{X,Y}(x,y)}{f_Y(y)} \quad \leftarrow \text{arriba: la rebanada; abajo: su peso.}$$

En el ejemplo

Columna $Y = 1$: 0,07; 0,15; 0,04; 0,03; 0,01 (suma $f_Y(1) = 0,30$). Dividiendo por 0,30: $f_{X/Y=1}(x) \approx 0,23$; 0,50; 0,13; 0,10; 0,03 para $x = 0,1,2,3,4$ (suma 1).

Independencia = todas las rebanadas tienen la misma forma. Si saber Y no cambia en nada la distribución de X , cada rebanada re-escalada es igual a la marginal de X . Eso es exactamente $f_{X,Y}(x,y) = f_X(x) f_Y(y)$ para todo (x,y) . Un solo cero en la tabla donde las marginales no son cero ya rompe la independencia: esa rebanada tiene un “hueco” que la marginal no tiene.

En el ejemplo

$f_{X,Y}(0,3) = 0$, pero $f_X(0) f_Y(3) = 0,19 \cdot 0,23 \approx 0,044 \neq 0 \Rightarrow X$ e Y **no** son independientes.


Cómo aparece en los ejercicios

“Determine las distribuciones marginales”, “si se sabe que $Y = \dots$, ¿cuál es la probabilidad de que...?” (condicional), “¿son independientes? Justifique”.

4. Covarianza: ¿se mueven juntas?

La idea en una frase

Parto el plano en cuatro cuadrantes con una cruz en el centro ($\mathbb{E}[Y], \mathbb{E}[X] = (1,55; 1,70)$). La covarianza mide si la arena está cargada hacia los cuadrantes “ambos arriba / ambos abajo” (positiva) o hacia los “uno arriba y otro abajo” (negativa).



$$\text{Cov}(X,Y) = \mathbb{E}[(X - \mathbb{E}[X])(Y - \mathbb{E}[Y])]$$

Cada montón aporta el producto de sus dos desviaciones: en los cuadrantes **verdes** ambas desviaciones tienen el mismo signo ((+)(+) o (-)(-)) y el aporte es positivo; en los **rojos** tienen signos opuestos y el aporte es negativo. La covarianza es el balance.

En el ejemplo

El 74% de la arena está en los cuadrantes verdes y sólo el 26% en los rojos $\Rightarrow \text{Cov}(X,Y) > 0$. Tiene sentido: en hora punta ambas filas se llenan, en hora tranquila ambas se vacían.

La fórmula práctica, $\text{Cov}(X,Y) = \mathbb{E}[XY] - \mathbb{E}[X]\mathbb{E}[Y]$, se lee así: $\mathbb{E}[X]\mathbb{E}[Y]$ es lo que valdría el promedio del producto *si las variables no tuvieran nada que ver*. La covarianza es el **exceso** (o déficit) del producto real sobre ese valor de referencia. Si los valores altos vienen juntos, los productos grandes aparecen más seguido de lo esperado y hay exceso.

En el ejemplo

$\mathbb{E}[XY] = \sum_x \sum_y xy f_{X,Y}(x,y) = 3,33$ (en cada casilla: x por y por su probabilidad, y se suma todo).
 $\text{Cov}(X,Y) = 3,33 - 1,70 \cdot 1,55 = 3,33 - 2,635 = 0,695$.

Por qué $\mathbb{E}[XY]$ necesita la conjunta y $\mathbb{E}[X]$ no: $\mathbb{E}[X]$ pregunta por X sola (basta la arena aplastada). $\mathbb{E}[XY]$ pregunta cómo se *combinan*: dos conjuntas con las mismas marginales pueden tener covarianzas muy distintas.

Sumas y restas: $\mathbb{V}[X \pm Y] = \mathbb{V}[X] + \mathbb{V}[Y] \pm 2\text{Cov}(X,Y)$.

En el ejemplo

$$\mathbb{V}[X + Y] = 1,59 + 1,0875 + 2 \cdot 0,695 = 4,0675 \quad \mathbb{V}[X - Y] = 1,59 + 1,0875 - 2 \cdot 0,695 = 1,2875$$

Si fueran independientes, ambas serían $\mathbb{V}[X] + \mathbb{V}[Y] = 2,6775$. Como las filas suben y bajan juntas, el total se *amplifica* (en hora punta ambas suben a la vez) y la diferencia se *estabiliza* (suben juntas, así que la resta cambia poco).

Cómo aparece en los ejercicios

“Calcule la covarianza”, “¿cómo es la asociación entre...?” (el signo dice si es directa o inversa; el tamaño de la covarianza *no* dice si es fuerte o débil). “Considere $D = X - Y$ (o el total $X + Y$), determine su valor esperado y su desviación estándar” $\Rightarrow$ se usa $\mathbb{V}[X \pm Y]$.

5. Correlación: la covarianza sin unidades

La covarianza tiene un problema: su tamaño depende de las unidades. Medir en horas o en minutos cambia el número por 60, sin que cambie la relación. La correlación la *normaliza*:

$$\rho = \frac{\text{Cov}(X,Y)}{\sigma_X \sigma_Y} = \frac{\text{Cov}(X,Y)}{\sqrt{\mathbb{V}[X] \mathbb{V}[Y]}} \in [-1,1].$$

La idea en una frase

ρ mide **qué tan bien se alinea la arena sobre una recta**. $\rho = \pm 1$: toda la arena sobre una línea. ρ cerca de 0: no hay tendencia *lineal*.

En el ejemplo

$$\rho = \frac{0,695}{\sqrt{1,59 \cdot 1,0875}} \approx 0,53: \text{asociación lineal directa y moderada.}$$

Ojo

$\rho = 0$ **no** significa independencia. Sólo detecta tendencias en línea recta.

- $X \in \{-1,0,1\}$ equiprobable e $Y = X^2$: Y está totalmente determinada por X , pero la arena forma una “V” simétrica y $\rho = 0$.
- Si el promedio de una variable es el mismo en todas las rebanadas pero su dispersión cambia de rebanada en rebanada: dependen, pero no hay tendencia de nivel, así que $\rho = 0$.

Independencia $\Rightarrow \rho = 0$. Al revés, no.

Cómo aparece en los ejercicios

“Determine el grado de asociación lineal”, “coeficiente de correlación. Interprete” $\Rightarrow$ decir signo (directa/inversa) y intensidad (débil, moderada, fuerte).

6. Esperanza condicional: el promedio dentro de un grupo

En esta sección y las dos siguientes uso siempre la misma dirección: **agrupo según** Y (clientes en la rápida) y **promedio** X (clientes en la tradicional). Cada columna de la tabla es un grupo.

La idea en una frase

$\mathbb{E}[X/Y = y]$ es el punto de equilibrio de **una sola rebanada** (la columna $Y = y$). Es tu mejor predicción de X cuando ya sabes cuánto vale Y .

$$\mathbb{E}[X/Y = y] = \sum_x x f_{X/Y=y}(x) = \frac{\sum_x x f_{X,Y}(x,y)}{f_Y(y)}$$


En el ejemplo

Columna $Y = 1$: $\mathbb{E}[X/Y = 1] = \frac{0 \cdot 0,07 + 1 \cdot 0,15 + 2 \cdot 0,04 + 3 \cdot 0,03 + 4 \cdot 0,01}{0,30} = \frac{0,36}{0,30} = 1,20$.

Haciendo lo mismo con cada columna:

$$\mathbb{E}[X/Y = 0] \approx 0,84 \quad \mathbb{E}[X/Y = 1] = 1,20 \quad \mathbb{E}[X/Y = 2] \approx 2,04 \quad \mathbb{E}[X/Y = 3] \approx 2,65$$

Mientras más gente hay en la rápida, más gente espero en la tradicional: es la covarianza positiva vista rebanada por rebanada.



Por qué es una función de y (y una variable aleatoria): hay un promedio distinto para cada rebanada. Antes de observar Y no sabes en qué rebanada caerás, así que $\mathbb{E}[X/Y]$ (sin fijar el valor) es aleatoria: vale 0,84 con probabilidad 0,19, vale 1,20 con probabilidad 0,30, etc.

Cómo se calcula en continuo: con y fijo, promedias X en esa rebanada: $\mathbb{E}[X/Y = y] = \int x f_{X/Y=y}(x) dx$. Se multiplica por x y se integra en dx ; el y sólo aparece como parámetro (en la densidad y en los límites), y por eso sobrevive en el resultado.

Ojo

Al revés funciona exactamente igual. Si agrupo según X (filas) y promedio Y , todo lo de esta sección y las dos siguientes vale cambiando los roles: $\mathbb{E}[Y/X = x] = \sum_y y f_{Y/X=x}(y)$. Lo único que cambia son los números: $\mathbb{E}[X/Y = y]$ y $\mathbb{E}[Y/X = x]$ son funciones distintas. En los ejercicios lo más común es $\mathbb{E}[Y/X = x]$.

Cómo aparece en los ejercicios

“¿Cuánto se espera que dure el proyecto **si** la etapa de diseño tomó x años?”, “calcule $\mathbb{E}[Y/X = 2]$ y $\mathbb{V}[Y/X = 2]$ ”. La palabra clave es *si se sabe que / dado que*: la respuesta es un número (valor fijo) o una función del valor conocido.

7. Esperanza iterada: promedio de promedios

La idea en una frase

El promedio global es el promedio de los promedios de cada grupo, **pesando cada grupo por su tamaño**.

$$\mathbb{E}[X] = \mathbb{E}[\mathbb{E}[X/Y]] = \sum_y \mathbb{E}[X/Y = y] f_Y(y)$$

Ejemplo de la vida real. Sección A: 30 alumnos, promedio 5,0. Sección B: 10 alumnos, promedio 6,0. El promedio del curso *no* es 5,5: la sección A pesa más.

$$5,0 \cdot \frac{30}{40} + 6,0 \cdot \frac{10}{40} = 5,25.$$

Es exactamente la esperanza iterada: el promedio de cada sección, pesado por el tamaño de la sección.

En el ejemplo

$$\mathbb{E}[X] = 0,84 \cdot 0,19 + 1,20 \cdot 0,30 + 2,04 \cdot 0,28 + 2,65 \cdot 0,23 \approx 1,70 \checkmark \text{ (el mismo } \mathbb{E}[X] \text{ de la sección 1).}$$

Dos pasos, dos integrales (o sumas): *adentro*, con y fijo, promedias X con la condicional (queda una función de y); *afuera*, promedias esa función con f_Y . Cada paso “borra” una variable.

Para qué sirve: te ahorra la marginal de la variable promediada cuando es fea (región por tramos) o cuando ni siquiera te dan la conjunta, sólo una marginal y datos de la condicional.

El mismo truco para $\mathbb{E}[XY]$. Dentro de una rebanada, Y es un número fijo: si sé que $Y = 2$, entonces $XY = 2X$ y su promedio es $2\mathbb{E}[X/Y = 2]$. Así:

$$\mathbb{E}[XY] = \mathbb{E}[Y \cdot \mathbb{E}[X/Y]] = \sum_y y \mathbb{E}[X/Y = y] f_Y(y).$$

Es sumar columna por columna: dentro de cada columna el y es el mismo y lo saco afuera.

En el ejemplo

$$\mathbb{E}[XY] = 1 \cdot 1,20 \cdot 0,30 + 2 \cdot 2,04 \cdot 0,28 + 3 \cdot 2,65 \cdot 0,23 \approx 3,33 \checkmark \text{ (igual que sumando casilla por casilla en la sección 4; la columna } y = 0 \text{ no aporta).}$$

Cómo aparece en los ejercicios

“Determine el tiempo esperado” cuando te dan una marginal y la condicional (sin la conjunta), “*sin calcular la marginal de...*”, determine...”, y cualquier covarianza en esos mismos ejercicios (vía $\mathbb{E}[XY]$ iterada).

8. Descomposición de la varianza: entre y dentro

La idea en una frase

$$\mathbb{V}[X] = \underbrace{\mathbb{V}[\mathbb{E}[X/Y]]}_{\text{Entre: dispersión de los promedios}} + \underbrace{\mathbb{E}[\mathbb{V}[X/Y]]}_{\text{Dentro: promedio de las dispersiones}}$$

Qué es cada parte:

- **Entre** = $\mathbb{V}[\mathbb{E}[X/Y]]$: tomo el promedio de cada grupo y miro qué tan distintos son esos promedios entre sí. Es la parte de la variabilidad de X que se *explica* por saber en qué grupo (Y) estás.

- **Dentro** = $\mathbb{E}[\mathbb{V}[X/Y]]$: calculo la varianza *adentro* de cada grupo y las promedio (pesando por el tamaño del grupo). Es la variabilidad que queda aunque sepas el grupo; la que *Y* no explica.

Las dos fuentes no se solapan (una es entre grupos, la otra es adentro de cada grupo), por eso se suman sin término cruzado.

Un caso real: los paralelos de matemática en la USM

Sea X la nota de un alumno en matemática y los grupos Y los paralelos.

Primer semestre: paralelos armados por carrera. Suponiendo que los alumnos de una misma carrera se parecen entre sí (misma formación, mismos intereses, mismo ritmo), cada paralelo es un grupo bastante *homogéneo*: adentro las notas son parecidas $\Rightarrow$ **Dentro chico**. Pero una carrera puede andar en promedio mucho mejor que otra, así que los promedios de los paralelos quedan muy distintos $\Rightarrow$ **Entre grande**. Saber en qué paralelo está alguien dice mucho de su nota.

Segundo semestre: paralelos mezclados. Ahora en cada paralelo hay alumnos de todas las carreras. Cada paralelo es una “muestra” de todo el universo, así que adentro hay notas de todo tipo $\Rightarrow$ **Dentro grande**. Y como todos los paralelos tienen la misma mezcla, sus promedios quedan parecidos $\Rightarrow$ **Entre chico**. Saber el paralelo ya casi no dice nada de la nota.

Lo más interesante: si fueran los mismos alumnos con las mismas notas, $\mathbb{V}[X]$ total *no cambiaría*. Mezclar no crea ni destruye variabilidad: sólo la **mueve** de la parte Entre a la parte Dentro.

Casos extremos para fijar la idea:

- X determinada por Y (ej. $X = 2Y$): cada rebanada es un solo punto $\Rightarrow$ Dentro = 0, todo es Entre.
- X e Y independientes: todas las rebanadas tienen el mismo promedio $\Rightarrow$ Entre = 0, todo es Dentro.

En el ejemplo

Varianzas dentro de cada columna: $\mathbb{V}[X/Y = y] \approx 0,66; 1,03; 1,61; 1,10$ para $y = 0,1,2,3$.

$$\text{Dentro} = \mathbb{E}[\mathbb{V}[X/Y]] \approx 0,66 \cdot 0,19 + 1,03 \cdot 0,30 + 1,61 \cdot 0,28 + 1,10 \cdot 0,23 \approx 1,135$$

$$\text{Entre} = \mathbb{V}[\mathbb{E}[X/Y]] = \mathbb{E}[\mathbb{E}[X/Y]^2] - \mathbb{E}[X]^2 \approx 3,345 - 2,89 \approx 0,455$$

$$\mathbb{V}[X] = 0,455 + 1,135 = 1,59 \quad \checkmark \quad (\text{Entre} \approx 29\%, \text{Dentro} \approx 71\%)$$

Saber cuántos hay en la rápida ayuda a predecir la tradicional, pero la mayor parte de la incertidumbre sigue ahí.

Conexión con ρ : cuando $\mathbb{E}[X/Y = y]$ es una recta en y , se cumple $\rho^2 = \frac{\text{Entre}}{\mathbb{V}[X]}$: la correlación al cuadrado es la fracción de la varianza que explica la otra variable. En el ejemplo los promedios *casi* forman una recta, y por eso los números casi coinciden: $\rho^2 \approx 0,28$ y $\text{Entre}/\mathbb{V}[X] \approx 0,29$.

Cómo aparece en los ejercicios

“Descomponga la varianza de Y en sus componentes *dentro* y *entre*. ¿Cuál aporta más a la variabilidad total?” $\Rightarrow$ calcular ambas, dividir cada una por la varianza total y comparar porcentajes, e interpretar (qué tanto explica la otra variable).

9. Resumen en una tabla

Concepto	Intuición	Qué necesito
$\mathbb{E}[X]$	Punto de equilibrio de la arena	Marginal de X
$\mathbb{V}[X]$	Momento de inercia respecto al centro	Marginal de X
Marginal f_X	Aplastar la arena contra un eje	Conjunta
Condiciona $f_{X/Y=y}$	Rebanar y re-escalar	Conjunta y marginal de Y
Independencia	Todas las rebanadas iguales	Comparar $f_{X,Y}$ con $f_X f_Y$
$\text{Cov}(X,Y)$	Balance de cuadrantes (¿se mueven juntas?)	Conjunta (o marginal + condicional)
$\mathbb{V}[X \pm Y]$	Se amplifica o se estabiliza según Cov	$\mathbb{V}[X]$, $\mathbb{V}[Y]$ y $\text{Cov}(X,Y)$
ρ	Qué tan alineada a una recta	$\text{Cov}(X,Y)$, $\mathbb{V}[X]$ y $\mathbb{V}[Y]$
$\mathbb{E}[X/Y = y]$	Equilibrio de una sola rebanada	Condiciona
$\mathbb{E}[\mathbb{E}[X/Y]]$	Promedio de promedios, ponderado	$\mathbb{E}[X/Y = y]$ y f_Y
Entre / Dentro	Lo que Y explica / lo que no	$\mathbb{E}[X/Y = y]$, $\mathbb{V}[X/Y = y]$ y f_Y